

# 半导体财报抽取式问答实验结论

材料为10家公司2025年报，共2086个PDF页；28073个分块。官方公告URL仍待补充，上传材料的官方真实性尚未核验。使用BM25与128维LSA统计向量，经RRF融合，再按主要会计数据表、研发投入表、产品句子和风险章节补充召回。同页正文分块按顺序合并，仍保留原始chunk\_ids。

方案A采用规则抽取和Python Decimal计算，未调用生成模型或付费API。回答包含公司、指标年度、来源报告年度、PDF页码、文件名、引用编号和原文；网页可打开原PDF对应页，下载真实问答JSON。财务报表需有三年列、明确金额单位及一致的指标；同比列与本期/上期金额交叉核算；跨公司金额换算成人民币亿元后排序，显式外币不擅自换算。未单列币种的元表补充召回同报告人民币本位币说明，并单独标注来源；缺少币种证据不作完整跨公司排名。

在真实浏览器逐题操作原evaluation/questions.csv的10道题，完成2道跨公司题。依据上传PDF核对的参考值、实际PDF页原文、回答字段及排序检查，本次10题均符合规则检查，其中9题给出抽取答案，第10题对2027年确定收入明确说明证据不足。33项事实/摘录引用均与对应PDF原页一致。所有结果均在响应完成后评价；答案正确性仍待用户人工复核，不等同教师验收或一般问题准确率。15项边界单元测试检查单位、外币、指标冲突、缺少公司、年度和同比等；另验证JSON下载、原PDF读取、非法输入和未知指标拒答。

跨公司结果：长电科技388.7134833123亿元 > 通富微电279.2142465615亿元 > 华天科技172.1391529379亿元。五家公司收入同比增速为澜起科技49.94% > 瑞芯微40.36% > 兆易创新25.12% > 全志科技24.04% > 北京君正12.54%。数值均由实际召回表格提取并计算，没有在实际应用中按题号或公司预填答案。参考值只存在独立测试资料中。

改进前的原检索第7题漏风险章节、第8/9题漏关键财务数值；此次增加章节/表头约束召回后补齐固定题集证据。仍存在明确局限：抽取规则依赖表格布局，未知指标不会自动泛化；历史收入不能预测未来；缺失单位、外币、同年冲突或缺少公司时返回不足/部分答案并停止完整排序；复杂跨页表格和不同会计口径须人工复核。未知指标网页失败/不足案例已截图，不能据10题通过声称任意财报问题都能回答。

大模型生成测试次数为0。抽取式答案不是生成式答案；本次截图、评价和10/10题集结果不得改写为“大模型问答通过”。仓库没有独立教师任务书；原README含生成问答阶段的说明，但不能据此断定教师必须要求大模型。若正式任务书要求生成模型或预训练语义嵌入，本方案尚未完成对应项。